Kỳ báo cáo: 7 – 9 tháng 11, 2026

Đề tài: Đánh giá gỡ bỏ tri thức mô hình trên TOFU

Báo cáo #05– Thứ Hai | Ngày nộp: 9 tháng 11, 2026 | Giai đoạn: Thí nghiệm

GitHub

Notebook chẩn đoán IDK+AP 3B trên Kaggle (riêng tư) | Bộ dữ liệu TOFU

1 Vấn đề nghiên cứu

Giai đoạn này đánh giá IDK+AP LoRA trên TOFU với Llama 3.2 3B, so sánh checkpoint sau unlearning với checkpoint full. Phân tích riêng hiệu quả quên trên `forget10` và mức duy trì năng lực trên `retain90`, `holdout10`. Protocol khóa trước gồm năm cổng thống kê; đây là chẩn đoán một seed, không phải kết luận xác nhận.

2 Tóm tắt tiến độ từ báo cáo trước

Pilot IDK+AP LoRA trên Llama 3.2 3B đã hoàn tất cả giai đoạn phát triển và đánh giá cuối với seed 42. Cả năm cổng phát triển đạt; trên cohort cuối, bốn trong năm cổng đạt, còn ROUGE-L của tập giữ lại không vượt ngưỡng không thua kém 5 điểm phần trăm một cách chắc chắn. ZIP đầu ra vượt qua CRC và bộ kiểm chứng độc lập xác nhận lại dữ liệu, receipt huấn luyện, độ phủ câu hỏi và bootstrap; trạng thái tổng thể theo protocol là không đạt.

3 Công việc đã hoàn thành

- **Đối chiếu phương pháp:** Objective IDK+AP khớp mã Open-Unlearning đã ghim; kiểm tra giá trị loss và gradient đều đạt.
- **Huấn luyện:** Hai cohort, mỗi cohort 5 epoch, 125 bước tối ưu, 200 câu quên và 2.760 câu retain dùng cho optimizer. Bounded smoke trên dữ liệu thật đạt; khởi tạo LoRA được khôi phục trước huấn luyện.
- **Đánh giá:** Cohort cuối gồm 200 câu forget, 400 retain và 200 holdout; khoảng tin cậy ghép cặp theo nhóm hồ sơ, 5.000 bootstrap, seed 42.
- **Kiểm chứng:** ZIP 186 MB có CRC đạt; kiểm chứng độc lập tính lại các cổng và xác nhận không có sai lệch hiện vật hay thống kê.

4 Công việc đang thực hiện

Hạng mục	Tình trạng hiện tại	Trạng thái
IDK+AP LoRA 3B	Đã hoàn tất. Bốn trong năm cổng cuối đạt; cổng ROUGE-L retain trượt sát ngưỡng.	Đã xác minh
Thiết kế xác nhận độc lập	Cần cohort chưa dùng trong các pilot trước và protocol khóa trước khi chạy tiếp.	Cần lập kế hoạch

5 Kết quả và phát hiện

Chênh lệch IDK+AP LoRA trừ checkpoint full trên cohort cuối:

Chỉ số	n / nhóm	Δ (điểm %)	KTC 95%	Cổng
forget10: Truth Ratio score	200 / 10	+2,03	[+1,72; +2,32]	Đạt
forget10: xác suất đáp án	200 / 10	−1,78	[−2,02; −1,52]	Đạt
retain90: xác suất đáp án	400 / 20	−1,74	[−1,88; −1,60]	Đạt
retain90: ROUGE-L recall	400 / 20	−3,06	[−5,11; −0,99]	Không đạt
holdout10: xác suất đáp án	200 / 10	+2,21	[+2,00; +2,42]	Đạt

Bảng 1: Chênh lệch candidate − full; KTC 95% bootstrap ghép cặp theo nhóm hồ sơ (5.000 lần, seed 42). Cổng tiện ích yêu cầu cận dưới lớn hơn −5 điểm phần trăm.

- Tín hiệu quên đạt nhưng nhỏ: xác suất đáp án mục tiêu giảm 1,78 điểm phần trăm; Truth Ratio score tăng 2,03 điểm.
- ROUGE-L retain giảm trung bình 3,06 điểm; cận dưới là −5,11, thấp hơn ngưỡng −5 đúng 0,11 điểm. Vì vậy kết quả cuối không đạt toàn bộ protocol dù 4/5 cổng đạt.
- Bộ dò chuỗi đơn giản không tìm thấy marker IDK trong 0/200 câu quên; đây không phải bộ phân loại ngữ nghĩa, nhưng không có bằng chứng về câu trả lời từ chối tường minh.

Đây là một seed, LoRA trên Llama 3.2 3B, không phải tái lập toàn tham số. Các nhóm hồ sơ cuối đã xuất hiện trong pilot NPO trước đó, nên kết quả ở cấp dự án vẫn mang tính thăm dò.

6 Vấn đề, trở ngại và hỗ trợ cần thiết

- IDK+AP có tín hiệu giảm likelihood trên forget nhưng chưa qua đủ cổng retain; không nên đổi ngưỡng sau khi xem kết quả.
- Các khối hồ sơ trong các split TOFU chuẩn đã được dùng cho huấn luyện hoặc đánh giá; cohort cuối cũng xuất hiện trong pilot NPO trước đó. Không còn cohort TOFU độc lập trong các split hiện tại.
- Log Kaggle ghi T4 x2 và receipt huấn luyện phân bổ mô hình trên CUDA 0/1, không offload; trường GPU ở receipt tổng thể bị để trống và cần sửa cho lần chạy sau.

7 Kế hoạch đến báo cáo tiếp theo

☐ Giữ nguyên kết quả IDK+AP hiện tại; không tinh chỉnh dựa trên cohort cuối đã xem.

☐ Chọn benchmark công khai mới với câu hỏi và thực thể chưa dùng; kiểm toán trùng lặp trước khi chạy.

☐ Khóa protocol, ngưỡng tiện ích và số seed trước khi chạy cohort phát triển mới; chỉ mở cohort cuối sau khi mọi cổng phát triển đạt.

8 Thông tin dự kiến gửi tạp chí/hội nghị

Chưa áp dụng; hiện chưa có kế hoạch gửi bài.

Nhận xét và xác nhận của người hướng dẫn

Người hướng dẫn	Chưa xác nhận
Ngày nhận xét	
Ý kiến	

Đồng hướng dẫn 1	Chưa xác nhận
Ngày nhận xét	
Ý kiến	

Đồng hướng dẫn 2	Chưa xác nhận
Ngày nhận xét	
Ý kiến	